# CSAPP lab4 cachelab实验报告

姓名: 吴晨曦

学号: 10242150443 实验日期: May.1-May.18

## 1实验解题思路

## 1.1 Part A: Writing a Cache Simulator

### 解题思路

#### 1.读取并解析命令行参数

- 通过 int main(int argc, char \*argv[]) 读取命令行的参数**数量(argc)**和**内容(argc)**
- 利用 getopt 函数来解析命令行参数,读取cache的基本参量 (s,E,b),模式参数(v)和文件名。并利用 switch case 来给对应的全局变量赋值。
- getopt 每次调用会返回当前解析到的选项字符(如 'v'、's'等)到 opt,如果没有更多选项可解析,则返回 -1。对应代码如下:

```
void parseCommand(int argc,char* argv[]){
    while((opt=getopt(argc,argv,"vs:E:b:t:"))!=-1){
        switch (opt){
            case 'v':
                verbose=1;//verbose模式
                break:
            case 's':
                s=atoi(optarg);
                S=1<< s;
                break:
            case 'E':
                E=atoi(optarg);
                break:
            case 'b':
                b=atoi(optarg);
                break:
            case 't':
                strcpy(filename,optarg);
                break;
            default:
                break:
            }
        }
    }
```

#### 2.逐行读文件中的trace

• 通过 FILE\* fp=fopen(filename,"r") 来读取文件;通过 fgets(buffer,1000,fp) 来以字符数组的形式读取每一行的trace;通过 n=sscanf(buffer,"%c %x,%d",&type,&address,&temp) 来从每一行的字符数组中按指定格式提取 type, address 及 temp (n为成功匹配的变量个数)。

- 输入的 trace 的格式为: [space] type address, size。 size 在此题中**没有用处**; address 是 **进行cache操作的参数**(决定在 cache 中是否命中); 操作的 type 有4 种, 决定**模拟cache需要进行操作的次数**。通过 switch case 进行选择。
  - I表示加载指令 (**不需要**任何操作)
  - L 加载数据(一次访问cache操作)
  - S存储数据(一次访问cache操作)
  - M 修改数据 (**两次**访问cache操作)

```
if(n<3){
    continue;
}//I加载指令的情况(不执行操作)
switch (type){
    case 'M':
        update(address);//刻意fall through 使M执行两次操作
    case 'L':
    case 'S':
        update(address);//L和S执行一次操作
        break;
}</pre>
```

### 3.定义并创建cache

• 定义set内的 cache\_line 数据结构。实际的 cache\_line 分为 valid 位, tag 位, block 位,但在本题中 block 位没有用处,所以不需要。由于采用LRU(最近最少使用)的替换策略,所以需要 stamp 时间戳来记录每一行 cache\_line 的数据距离上一次使用的时间。

```
typedef struct{
    int valid,tag,stamp;//stamp是时间戳 用于记录最近最少使用
}cache_line;
```

• 注:由于stamp时间戳是用于记录cache\_line距离上一次使用的时间,所以注意**在每一行 trace的操作后,所有非空的cache\_line都要进行stamp的更新!** 

• 使用malloc动态分配cahce所需空间并进行初始化。

```
cache_line** cache=NULL;//指向cache的指针 全局变量
void cacheSimulate(char* filename){
    //开辟cache所需空间
    cache=(cache_line**)malloc(sizeof(cache_line*)*S);//为cache开辟S个set的空间
    for(int i=0;i<S;i++){
```

```
cache[i]=(cache_line*)malloc(sizeof(cache_line)*E);
}//为每一个set开辟E行cache_line的空间
//对cache初始化
for(int i=0;i<S;i++){
    for(int j=0;j<E;j++){
        cache[i][j].valid=0;
        cache[i][j].tag=cache[i][j].stamp=-1;
    }
}
```

## 4.cache操作 (update函数,用于判断是否hit/miss/eviction)

• 从 address 地址中提取用于定位的 set (定位组)和 tag (定位行)。

```
unsigned set=(address>>b)&((1<<s)-1);
unsigned tag=address>>(s+b);
```

- 在对应的set中查找**是否命中**。若是**tag匹配且valid位为1**,则命中,hit\_count 加1,**同时更新时间戳stamp为0(表示刚刚使用过)**;否则未命中,miss\_count 加1。
- miss的情况下,再查找**是否需要替换**。若是存在空cache\_line(即valid为0的cache\_line),则不需要替换,将新的地址存入该行即可,同时更新时间戳stamp为0(表示刚刚使用过);若是不存在空cache\_line,则需要替换,eviction\_count 加1,同时查找最近最少使用的(即时间戳最大的)行进行替换,并更新时间戳。对应代码如下:

```
void update(unsigned address){
   unsigned set=(address>>b)&((1<<s)-1);
   unsigned tag=address>>(s+b);
   //命中的情况
   for(int i=0;i<E;i++){
       if(cache[set][i].tag==tag & cache[set][i].valid){//tag匹配且vilid为1
则匹配
           hit_count++;
           cache[set][i].stamp=0;//更新时间戳
           if(verbose) printf("hit "); //verbose模式要打印
           return;
       }
   //未命中的情况
   miss_count++;
   if(verbose) printf("miss ");
   ///存在空line
   for(int i=0;i<E;i++){</pre>
        if(cache[set][i].valid==0){
           cache[set][i].valid=1;
           cache[set][i].tag=tag;
           cache[set][i].stamp=0;//更新时间戳
           return;
       }
   ///没有空line 只能替换
   eviction_count++;
   if(verbose) printf("eviction ");
   int max_stamp_index=0;
```

```
for(int i=1;i<E;i++){
    if(cache[set][i].stamp>cache[set][max_stamp_index].stamp){
        max_stamp_index=i;
    }
}//找到最近最少使用(即搁置最久)
cache[set][max_stamp_index].tag=tag;//进行替换
cache[set][max_stamp_index].stamp=0;//更新时间戳
return;
}
```

#### 5.整合(主函数)

• 总结下来,整体的步骤为:解析命令行,读取trace,创建cache,更新cache(进行访问操作), 释放内存,输出结果。主函数代码如下:

```
int main(int argc,char *argv[]){
    parseCommand(argc,argv);//解析命令行
    cacheSimulate(filename);//模拟cache(包含读取trace, 创建cache与更新cache)
    for(int i=0;i<S;i++){
        free(cache[i]);
    }
    free(cache);//释放内存
    printSummary(hit_count,miss_count,eviction_count);//输出结果
    return 0;
}</pre>
```

## partA全部代码及注释:

```
#include "cachelab.h"
#include <getopt.h>//用于解析命令行参数(如optarg)
#include <stdlib.h>
#include <unistd.h>//getopt定义在这里
#include <string.h>
#include <stdio.h>
//定义一些需要用到的全局变量
static int verbose=0;
static int s;//set位的字节数
static int S;//总共有多少set
static int E;
static int b;//block位的字节数
static int hit_count=0;
static int miss_count=0;
static int eviction_count=0;
//定义cache_line的结构
typedef struct{
   int valid,tag,stamp;//stamp是时间戳 用于识别最近最少使用的cache_line
}cache_line;
cache_line** cache=NULL;//cache为全局变量
char filename[100];//输入的文件名
//解析命令行参数
void parseCommand(int argc,char* argv[]){
   int opt;
   while((opt=getopt(argc,argv,"vs:E:b:t:"))!=-1){
```

```
switch (opt){
           case 'v':
               verbose=1;//verbose模式
               break:
           case 's':
               s=atoi(optarg);
               S=1<<s;
               break:
           case 'E':
               E=atoi(optarg);
               break:
           case 'b':
               b=atoi(optarg);
               break;
            case 't':
               strcpy(filename,optarg);
               break;
           default:
               break;
           }
       }
    }
//对cache进行操作(hit/miss/eviction)
void update(unsigned address){
    unsigned set=(address>>b)&((1<<s)-1);
    unsigned tag=address>>(s+b);
    for(int i=0;i<E;i++){
       if(cache[set][i].tag==tag && cache[set][i].valid){//tag匹配且valid为1才hit
           hit_count++;
           cache[set][i].stamp=0;//更新时间戳
           if(verbose) printf("hit ");//verbose模式要打印
           return;
       }
   }//hit
   miss_count++;//未hit都先miss
   if(verbose) printf("miss ");
    //接下来检查该组是否有空的cache_line
    for(int i=0;i<E;i++){
       if(cache[set][i].valid==0){
           cache[set][i].valid=1;
           cache[set][i].tag=tag;
           cache[set][i].stamp=0;
           return;
       }
    }//存在空line
    eviction_count++;//没有空line 只能eviction替换
    if(verbose) printf("eviction ");
    int max_stamp_index=0;
    for(int i=1;i<E;i++){
       if(cache[set][i].stamp>cache[set][max_stamp_index].stamp){
           max_stamp_index=i;
       }
    }//找到最近最少使用(即搁置最久)
    cache[set][max_stamp_index].tag=tag;
    cache[set][max_stamp_index].stamp=0;//进行替换
```

```
return;
}
//时间戳更新
void stamp_update(){
    for(int i=0;i<S;i++){</pre>
       for(int j=0; j<E; j++){
           if(cache[i][j].valid){//所有不为空的cache_line
               cache[i][j].stamp++;//时间都增加
           }
        }
   }
    return;
}
//读文件 根据不同的操作进行模拟
void cacheSimulate(char* filename){
    //动态开辟cache的空间
    cache=(cache_line**)malloc(sizeof(cache_line*)*S);
    for(int i=0;i<S;i++){
       cache[i]=(cache_line*)malloc(sizeof(cache_line)*E);
    }
    //cache初始化
    for(int i=0;i<S;i++){</pre>
       for(int j=0; j<E; j++){
           cache[i][j].valid=0;
           cache[i][j].tag=cache[i][j].stamp=-1;
       }
    }
    //读文件
    FILE* fp=fopen(filename, "r");
    if(fp==NULL){
       printf("the file is wrong");
       exit(-1);//文件错误 立即终止当前程序
    char buffer[1000];
    char type;//操作类型
    unsigned int address;//地址
    int temp;//block位 在本题中没用
    while(fgets(buffer,1000,fp)){//fgets成功时返回buffer,文件末尾返回null
       int n=sscanf(buffer," %c %x,%d",&type,&address,&temp);
       //从字符串中按指定格式提取数据 sscanf返回值为成功匹配的变量个数
       if(n<3){
           continue;
       }//处理type为'I'的情况
       if(verbose){
           printf("%c %x,%d ",type,address,temp);
       }//verbose模式 要打印
       switch (type)
        {
               update(address);//fall through 使M模式操作两次
           case 'L':
           case 'S':
               update(address);
               break:
```

```
}//M模式要操作两次 L/S操作一次
        if(verbose) printf("\n");
        stamp_update();//一次操作后时间戳update
    }
    fclose(fp);
    return;
}
int main(int argc,char *argv[]){
    //解析命令行
    parseCommand(argc,argv);
    //模拟cache行为
    cacheSimulate(filename);
    for(int i=0;i<S;i++){</pre>
       free(cache[i]);
    }
    free(cache);
    //打印结果
    printSummary(hit_count, miss_count, eviction_count);
    return 0;
}
```

## 1.2 Part B: Optimizing Matrix Transpose

题目给出的cache参数为 s = 5, E = 1, b = 5, 是一个**直接映射高速缓存**(每组只有一行),有**32个组**(2的 s 次方),每行32个bits(2的 b 次方),**每行(组)可存8个** int 。

#### 1.2.1 32x32

#### 未优化前的暴力做法分析

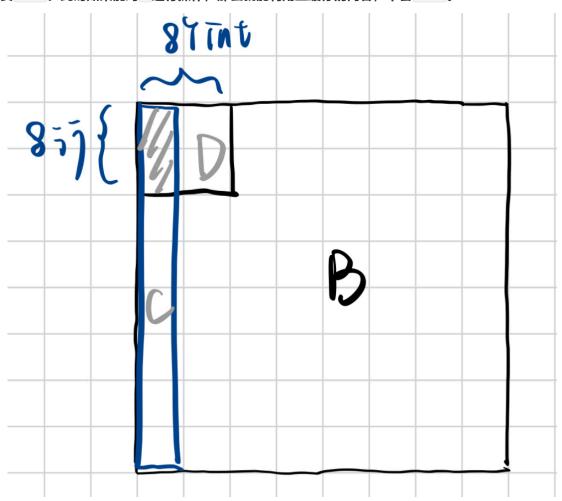
• 未进行优化前,函数**按行读取 A 矩阵,然后按列写入 B 矩阵**。实际跑出的结果**miss1184次**,远远路出题目要求的次数。

```
Function 1 (5 total)
Step 1: Validating and generating memory traces
Step 2: Evaluating performance (s=5, E=1, b=5)
func 1 (Simple row-wise scan transpose): hits:869, misses:1184, evictions:1152
```

- 对于 A, 以读A的第1行为例,在读 A[0][0] 时,除了 A[0][0] 被加载到cache中,它之后的 A[0][1]---A[0][7] 也被加载进cache。因为A刚好是按行读取的,所以在接下来读 A[0][1]--- A[0][7] 时不需要重新加载,每一行会有 32/8 = 4 次不命中,所以读 A 大概共4x32次miss。
- 然而对于 B,由于 B 是按列写入,而在列上相邻的元素不在一个内存块上,所以**每次写入都不命中缓存**。并且一列写完读下一列时,原来的缓存可能被覆盖了,这样就又会不命中。考虑最坏情况, B 的每一列都有 32 次不命中,**所以写 B 大概共32x32次miss**。
- 未优化前理论的miss为4 × 32 + 32 × 32 = 1152次,比实际的miss(1184)少了一点,这是由于 A 和 B 的地址由于取余关系,每个元素对应的地址是相同的,对角线部分两者会冲突,导致了更多的 miss。

#### 优化的做法

• 由上面暴力做法导致miss的原因分析可知,主要需要优化的部分在于写 B 时缓存的利用。如图,在写入 B 的前 8 行后, B 的 D 区域就进入了缓存,而未优化解法接下来操作的是 C,每一个元素的写都要驱逐之前的缓存区,当来到第 2 列继续写 D 时,它对应的缓存行很可能已经被驱逐了,于是又要 miss。此时如果能对 D 进行操作,那么就能利用上缓存的内容,不会 miss。



• 于是考虑分块,由于 A 中的元素对应的缓存行每隔8行就会重复,尝试8x8分块,代码如下:

### 结果如下:

```
Function 2 (5 total)

Step 1: Validating and generating memory traces

Step 2: Evaluating performance (s=5. E=1. b=5)

func 2 (8*8 blocking): hits:1709, misses:344, evictions:312
```

miss344次,仍然未达到题目的要求,比预期的每8次miss一次算出的4x2x32=256多了很多。

- 考虑**对角线上的块**。 A 与 B 对角线上的块**在缓存中对应的位置是相同的,而它们在转置过程中位置不变**,所以复制过程中会发生**相互冲突**。以 A 的一个对角线块 p , B 与 p 相应的对角线块 q 为例,复制前, p 在缓存中。 复制时, q 会驱逐 p 。 下一个开始复制 p 又被重新加载进入缓存驱逐 q ,这样就会**多产生两次** miss 。
- 于是使用**局部变量**一次性存下A的一行再复制给B,减少重复交替访问造成的miss,代码如下(代码中3个循环局部变量,8个局部变量,共11个局部变量,符合题目至多12个局部变量的要求):

```
for(int n=0; n< N; n+=8){
            for(int m=0;m<M;m+=8){//分成8*8的小块
                for(int i=n;i<n+8;i++){</pre>
                    a=A[i][m];
                    b=A[i][m+1];
                    c=A[i][m+2];
                    d=A[i][m+3];
                    e=A[i][m+4];
                    f=A[i][m+5];
                    g=A[i][m+6];
                    h=A[i][m+7];//使用8个局部变量,暂存A的一行
                    B[m][i]=a;
                    B[m+1][i]=b;
                    B[m+2][i]=c;
                    B[m+3][i]=d;
                    B[m+4][i]=e;
                    B[m+5][i]=f;
                    B[m+6][i]=g;
                    B[m+7][i]=h;
                }
            }
        }
```

#### 结果如下:

```
Function 0 (5 total)
Step 1: Validating and generating memory traces
Step 2: Evaluating performance (s=5, E=1, b=5)
func 0 (Transpose submission): hits:1765, misses:288, evictions:256
```

满足要求!

### 1.2.2 64x64

#### 尝试8x8分块

```
Function 1 (5 total)
Step 1: Validating and generating memory traces
Step 2: Evaluating performance (s=5, E=1, b=5)
func 1 (Simple row-wise scan transpose): hits:3473, misses:4724, evictions:4692

Function 2 (5 total)
Step 1: Validating and generating memory traces
Step 2: Evaluating performance (s=5, E=1, b=5)
func 2 (8*8 blocking) hits:3473, misses:4724, evictions:4692
```

• 发现**8x8分块**的效果和**暴力做法**一致,都是4724次miss

• 原因是64x64 的矩阵**4 行**即可占满cache,所以8x8 分块后,**上半块和下半块的数据会发生冲突不命** 中,导致miss增加

#### 改为4x4分块

代码如下:

#### 结果如下:

```
Function 4 (5 total)

Step 1: Validating and generating memory traces

Step 2: Evaluating performance (s=5, E=1, b=5)

func 4 (simply 4*4 blocking for 64*64): hits:6305, misses:1892, evictions:1860
```

miss的数量明显减少了,为1892,但仍然未达到题目满分的要求。

#### 先 8x8 分大块, 再在每个大块内 4x4 分小块

- 读完 A 的第一行(8 个 int)后,先将前 4 个正常转置并写入 B,然后**将后 4 个先放到B的右上角暂时存储,这样就可以避免写下半块时的冲突不命中。**
- 于是具体步骤及对应的miss情况为: (以下A表示A矩阵的一个8x8分块, B表示B矩阵的一个8x8分块)
  - 1. **读A的前四行同时转置放入B的前四行**(放入后B的左上角已为最终结果,B的右上角暂存了最终的左下角)
  - 。 无论是否为对角线上元素, 读A每行会miss一次, 共miss四次
  - o 若非对角线上的块,B在写入第一列时miss四次,之后无miss,共miss四次
  - 若为对角线上的块, B在第二/三/四次循环时都需要覆盖对应的A的第二/三/四行, 多miss三次, 共miss七次

执行完这一步后,缓冲区中是A的上半部分及B的上半部分

2. 将A的左下角转置到B的右上角,同时把B右上角暂存的复制到B的左下角

#### 读时的miss:

- 。 读A的左下角的一列,会miss四次。若为对角线块,还会因为循环间读B,读后三列时共**多三次miss**
- 若为非对角线上的块,再读B时因为B在上一步时已存于缓存区,不会造成miss
- 若为**对角线上的块**,再读**B**时每次都会因为之前读A造成miss,**共四次miss**

#### 写时的miss:

- 。 在读完B的右上角后写B的右上角,不会造成miss
- 。 每次写B的左下角造成一次miss, 共四次miss

此步中先读A再读B效果一致,执行完后缓冲区中有B的下半部分及A的下半部分(若为非对角线块),或A的下半部分除最后一行及B的最后一行(若为对角线元素)

#### 3. 将A的右下角先复制再转置到B的右下角

复制:

- 若为非对角线元素,复制前所需部分均在缓冲区中,**没有miss**
- 若为对角线元素,因为上一部分最后是写 B 的最后一行,但是其他行都是正常的,所以 读 A 时会出现 1 次冲突不命中。读完 A 写 B 时,必定出现冲突不命中,每次循环 1 次 miss,所以总计造成**五次miss**

转置:

- B的右小角均在缓冲区中,**自身转置没有miss**
- 完整代码如下:

```
int a,b,c,d,e,f,g,h;
int k;
for(int m=0; m<64; m+=8){//行}
    for(int n=0; n<64; n+=8){//列}
              for(k=0; k<4; k++){
                    a=A[m+k][n];
                    b=A[m+k][n+1];
                    c=A[m+k][n+2];
                    d=A\lceil m+k\rceil\lceil n+3\rceil;
                    e=A[m+k][n+4];
                    f=A[m+k][n+5];
                    g=A[m+k][n+6];
                    h=A[m+k][n+7];//从A中取前四行(循环下来共会有4次miss)
                    B[n][m+k]=a;
                    B[n+1][m+k]=b;
                    B[n+2][m+k]=c;
                    B[n+3][m+k]=d;
                    B[n][m+k+4]=e;
                    B[n+1][m+k+4]=f;
                    B[n+2][m+k+4]=g;//!注意A的行号是B的列号! 写矩阵索引的时候注意!
                    B[n+3][m+k+4]=h;//转置后读到B的上半部分(共4次miss)
              for (k=0; k<4; k++) {
                    a=A[m+4][n+k];
                    b=A[m+5][n+k];
                    c=A[m+6][n+k];
                    d=A[m+7][n+k];//存A
                    e=B[n+k][m+4];
                    f=B[n+k][m+5];
                    g=B[n+k][m+6];
                    h=B[n+k][m+7];//存B
                    B[n+k][m+4]=a;
                    B[n+k][m+5]=b;
                    B[n+k][m+6]=c;
                    B[n+k][m+7]=d;//读完B右上角后写B右上角 减少miss
                    B[n+k+4][m]=e;
                    B[n+k+4][m+1]=f;
                    B[n+k+4][m+2]=g;
```

```
B[n+k+4][m+3]=h;//写B左下角
             }//把A的左下角转置到B的右上角 同时把B右上角复制到B的左下角
             for (k=4; k<8; k++) {
                   a=A[m+k][n+4];
                   b=A[m+k][n+5];
                   c=A[m+k][n+6];
                   d=A[m+k][n+7];
                   B[n+k][m+4]=a;
                   B[n+k][m+5]=b;
                   B[n+k][m+6]=c;
                   B[n+k][m+7]=d;
             }//把A的右下角先复制到B的右下角
             for (k=4; k<8; k++) {
                   for(int i=k+1; i<8; i++){
                       a=B[n+k][m+i];
                      B[n+k][m+i]=B[n+i][m+k];//!
                      B[n+i][m+k]=a;
             }//在B处进行转置 防止出现多余的miss
   }
}
```

• 运行结果如下:

```
Function 0 (5 total)

Step 1: Validating and generating memory traces

Step 2: Evaluating performance (s=5, E=1, b=5)

func 0 (Transpose submission): hits:10633, misses:1148, evictions:1116
```

miss数为1148,满足要求!

#### 1.2.3 61x67

- 本题对于miss数目的要求较低,尝试不同的分块,发现分块大小为16x16,17x17,18x18时均小于2000
- 分块大小为17x17时,代码如下:

```
for(int n=0;n<N;n+=17){
    for(int m=0;m<M;m+=17){//分成17*17的小块
        for(int i=n;i<n+17&&i<N;i++){
            for(int j=m;j<m+17&&j<M;j++){
                B[j][i]=A[i][j];
            }
        }
    }
}
```

### 结果如下:

```
Function 0 (5 total)

Step 1: Validating and generating memory traces

Step 2: Evaluating performance (s=5, E=1, b=5)

func 0 (Transpose submission): hits:6228, misses:1951, evictions:1919
```

miss数为1951,满足要求!

## 2实验中遇到和解决的问题

## 2.1对角线上A和B的地址重合问题

#### 问题:

发现32x32矩阵在8x8分块后miss344次,仍然未达到题目的要求,比预期算出的4x2x32=256多了很多

#### 解决:

- 查看 tracegen.c 文件,发现无论 M,N 设定什么值,A 和 B 都是存在 256x256 大小的静态数组中的,256x256 是题目给定的cache大小的整数倍,因此由于取余的关系,**A和B在相同位置上的元素将会缓存在相同的** cache\_line 中。
- 原来计算的时候只考虑了非对角线上的元素(地址不重合的情况),没有考虑**对角线上的元素**。而对角线上的元素会因为地址冲突而造成**缓存抖动**。以 A 的一个对角线块 p, B 与 p 相应的对角线块 q 为例,复制前, p 在缓存中。 复制时, q 会驱逐 p 。 下一个开始复制 p 又被重新加载进入缓存驱逐 q ,**这样的重复替换就会多产生两次** miss。
- 具体的解决策略为:使用**局部变量**一次性存下A的一行再复制给B,从而减少重复交替访问造成的 miss。

## 3实验最终结果截图

